Classification de sentiments dans les avis sur les médicaments

Comparaison de cellules LSTM Vanilla CIFG et WMC

Rapport expérimental du projet RNN | 20 octobre 2026

Résumé

Nous comparons trois cellules récurrentes implémentées manuellement en PyTorch pour classer les avis du corpus Drug Review en sentiments négatif, neutre ou positif. Le protocole utilise les mêmes partitions, un vocabulaire appris sur l'entraînement et une sélection par Macro-F1 de validation. Des essais complémentaires portent sur l'optimiseur, le taux d'apprentissage et la taille des lots du modèle Vanilla. **CIFG est retenu avant l'évaluation finale** : sur 48 266 avis de test, il atteint **71,59 % d'accuracy et 0,5923 de Macro-F1**. Les erreurs sur la classe neutre constituent la principale limite observée.

1 Objectif et données

L'objectif est d'étudier comment la structure des portes d'un LSTM influence la classification de séquences textuelles. La comparaison porte sur un LSTM classique, une variante à portes couplées CIFG et une variante WMC qui utilise la mémoire interne dans le calcul des portes. Le corpus provient des avis Drugs.com distribués par UCI [1]. Le modèle reçoit uniquement le texte ; la note sert à construire la cible, sans être utilisée comme variable d'entrée.

Les notes de **1 à 4** définissent la classe négative, celles de **5 à 6** la classe neutre et celles de **7 à 10** la classe positive. Cette conversion constitue une approximation du sentiment exprimé : un texte peut décrire simultanément un effet bénéfique et des effets indésirables.

Partition	Négatifs	Neutres	Positifs	Total
Entraînement	15 781	5 678	42 681	64 140
Validation	3 946	1 419	10 671	16 036
Test	12 095	4 334	31 837	48 266

Tableau 1 - Effectifs réellement présents dans les fichiers exportés après préparation.

Nettoyage et prévention des recouvrements

Les observations sans texte ou sans note, les notes hors de l'intervalle 1 à 10 et les textes vides sont écartés. Le nettoyage décode les entités HTML, passe en minuscules et uniformise les espaces, tout en conservant la ponctuation. Les doublons de texte nettoyé sont supprimés dans chaque source. Les textes de la source d'entraînement également présents dans le test sont retirés de l'entraînement. Une séparation stratifiée réserve ensuite 20 % du reste à la validation, avec la graine 42.

Les trois partitions ne partagent aucun texte nettoyé identique. Cette vérification ne supprime toutefois pas nécessairement les quasi-doublons, ni les dépendances entre avis portant sur un même médicament. Les positifs représentent 66,55 % de l'entraînement ; les neutres seulement 8,85 %. Ce déséquilibre justifie une évaluation qui accorde le même poids aux trois classes.

2 Représentation des textes et architectures

La tokenisation distingue les mots, les apostrophes internes et la ponctuation. Le vocabulaire est construit uniquement sur l'entraînement, avec au plus 20 000 entrées incluant les symboles de remplissage et de mot inconnu. Chaque avis est tronqué aux 128 premiers tokens. Les séquences sont complétées à la longueur maximale du lot ; un masque conserve les états caché et mémoire après la fin de chaque avis, afin que le remplissage ne modifie pas la représentation finale.

Les modèles partagent un embedding appris de dimension 128, un état caché de dimension 128, une seule couche récurrente et un dropout de 0,3 appliqué à l'état final. Une couche linéaire produit trois logits. La perte reçoit directement ces logits, sans softmax préalable. Les cellules étudiées sont écrites avec **nn.Linear** et des opérations élémentaires ; elles n'utilisent pas de couche **nn.LSTM** prédéfinie.

LSTM Vanilla

À l'instant t, les portes d'entrée i, d'oubli f et de sortie o dépendent de l'entrée x et de l'état caché précédent h. Le candidat g utilise une tangente hyperbolique ; les trois portes utilisent une sigmoïde. En notant ⊙ le produit terme à terme, les mises à jour sont :

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$
$$h_t = o_t \odot \tanh(c_t)$$

CIFG et WMC

La variante **CIFG** couple les portes d'entrée et d'oubli : $i_t = 1 - f_t$. Trois transformations groupées remplacent les quatre du modèle classique. Ce couplage réduit le nombre de paramètres de la cellule et impose un compromis explicite entre conservation et écriture en mémoire [2].

La variante **WMC** ajoute aux préactivations des portes d'entrée et d'oubli des projections apprises $\tanh(C_i c_{t-1})$ et $\tanh(C_f c_{t-1})$. La porte de sortie reçoit $\tanh(C_o c_t)$, calculé avec la nouvelle mémoire. Ces trois matrices sans biais permettent aux portes d'exploiter directement le contenu de la cellule [3].

Architecture	Paramètres entraînables	Écart face à Vanilla
Vanilla	2 691 971	Référence
CIFG	2 659 075	−32 896 soit −1,22 %
WMC	2 741 123	+49 152 soit +1,83 %

Tableau 2 - Comptages exportés par le notebook, embedding et classifieur inclus. L'embedding contient à lui seul 2 560 000 paramètres ; la réduction de la cellule CIFG est donc peu visible dans le total.

3 Protocole expérimental

Les trois architectures de référence sont entraînées pendant cinq époques avec Adam, un taux d'apprentissage de 0,001 et des lots de 64. Les gradients sont limités à une norme de 1,0. La graine est fixée à 42 et le générateur de mélange des lots est réinitialisé pour chaque expérience. Les données et les dimensions sont communes ; les architectures ont cependant des initialisations distinctes en raison de leur structure.

La perte est une entropie croisée pondérée par $w_k = N / (3\, n_k)$, calculée à partir de l'entraînement : environ 1,3548 pour les négatifs, 3,7654 pour les neutres et 0,5009 pour les positifs. La perte d'un lot est divisée par la somme des poids des cibles de ce lot. Le meilleur état est conservé selon le **Macro-F1 de validation**, et non selon la dernière époque ou la perte minimale.

4 Validation et choix des hyperparamètres

Le Macro-F1 est la moyenne arithmétique des F1 des trois classes. Il évite qu'une bonne reconnaissance de la classe positive majoritaire masque les difficultés sur les neutres. L'accuracy reste rapportée en complément. Le test n'intervient ni dans le réglage des hyperparamètres, ni dans le choix du modèle final.

Architecture	Époque retenue	Accuracy validation	Macro-F1 validation
Vanilla	4	68,45 %	0,5816
CIFG	5	71,66 %	0,5907
WMC	5	70,68 %	0,5856

Tableau 3 - Meilleur état de chaque architecture selon la validation.

CIFG obtient le meilleur Macro-F1 de validation, soit 0,5907, devant WMC à 0,5856 et Vanilla à 0,5816. Son gain sur Vanilla est de 0,0092 point de score, avec moins de paramètres. Sur une seule graine, cette différence reste un résultat descriptif et ne démontre pas une supériorité statistiquement établie.

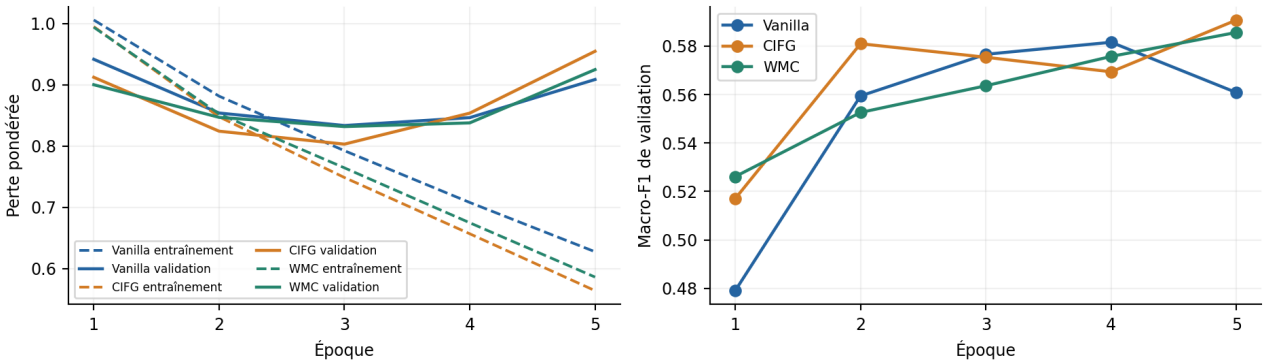


Figure 1 - Historique des cinq époques des trois architectures de référence. Les pertes sont pondérées ; les courbes de droite représentent le Macro-F1 de validation.

Les pertes d'entraînement diminuent, tandis que les pertes de validation remontent en fin d'apprentissage : ce comportement est compatible avec un surapprentissage. La perte et le Macro-F1 n'optimisent pas le même objectif. Ainsi, pour CIFG, la perte de validation est minimale à l'époque 3, mais le Macro-F1 maximal à l'époque 5 ; cette dernière est retenue conformément au critère fixé.

Réglages complémentaires du modèle Vanilla

Optimiseur	Taux	Lot	Époque	Acc. val.	Macro-F1 val.
Adam	0,001	64	4	68,45 %	0,5816
Adam	0,0003	64	5	66,16 %	0,5654
RMSprop	0,001	64	5	72,04 %	0,5871
Adam	0,001	128	4	70,73 %	0,5794

Tableau 4 - Essais à cinq époques maximum, sur les mêmes partitions.

RMSprop est le meilleur réglage testé pour Vanilla. Il augmente le Macro-F1 de validation de 0,0055 par rapport à Adam avec lots de 64. Le taux 0,0003 est moins performant dans le budget de cinq époques ; cela ne permet pas de conclure qu'il serait toujours inférieur après un entraînement plus long. Les lots de 128 améliorent l'accuracy, sans améliorer le Macro-F1. CIFG reste devant le Vanilla réglé sur le critère principal et est donc sélectionné avant le test.

5 Résultats sur le jeu de test

Après fixation du choix sur la validation, les trois références et le meilleur Vanilla réglé sont évalués sur les 48 266 avis de test. Le modèle final reste CIFG ; les scores de test ne servent pas à réajuster ce choix.

Modèle	Perte test	Accuracy test	Macro-F1 test
Vanilla	0,8601	68,35 %	0,5771
CIFG	0,9651	71,59 %	0,5923
WMC	0,9333	70,68 %	0,5857
Vanilla réglé	0,9052	71,97 %	0,5874

Tableau 5 - Résultats de test des meilleurs états choisis sur la validation.

CIFG atteint 0,5923 de Macro-F1 et 71,59 % d'accuracy. Son gain de Macro-F1 est de 0,0151 face à Vanilla, 0,0066 face à WMC et 0,0049 face au Vanilla réglé. Le Vanilla réglé obtient l'accuracy maximale, 71,97 %, mais son Macro-F1 est inférieur. Cette divergence confirme l'intérêt de conserver le critère de sélection adapté au déséquilibre des classes.

Classe CIFG	Précision	Rappel	F1	Effectif
Négatif	0,6569	0,7428	0,6972	12 095
Neutre	0,1939	0,3724	0,2550	4 334
Positif	0,9120	0,7524	0,8245	31 837

Tableau 6 - Mesures par classe du modèle final CIFG.

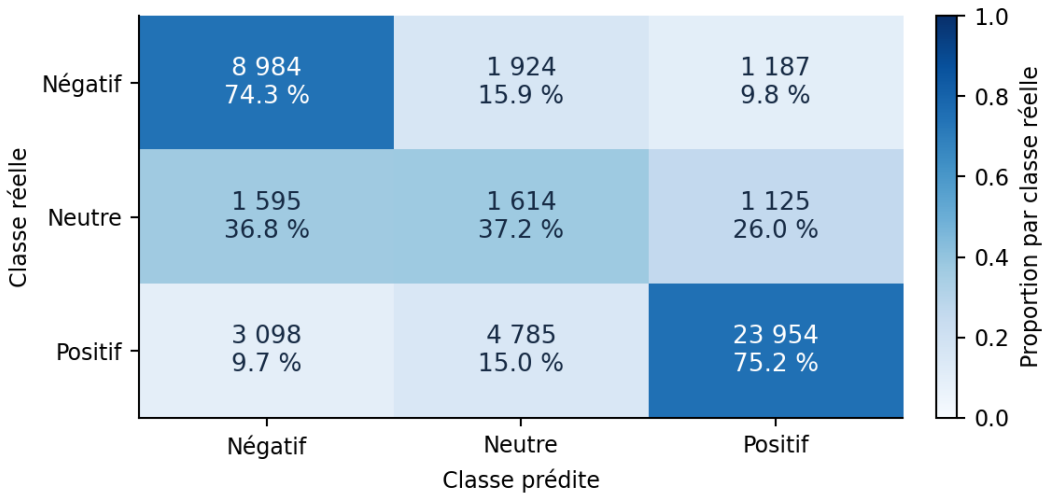


Figure 2 - Matrice de confusion CIFG. Chaque case indique l'effectif puis le pourcentage de la classe réelle. Les lignes correspondent aux cibles et les colonnes aux prédictions.

Les avis positifs sont les mieux reconnus selon le F1. Pour les neutres, seuls 1 614 avis sur 4 334 sont correctement classés : 1 595 sont prédits négatifs et 1 125 positifs. Inversement, 4 785 avis positifs sont prédits neutres, ce qui contribue à la faible précision de cette classe. Le poids élevé des neutres dans la perte peut participer au compromis rappel-précision, mais aucune ablation ne permet ici d'en isoler l'effet.

6 Discussion et limites

Qualité de classification et coût de calcul

Dans ce protocole, CIFG offre le meilleur compromis entre Macro-F1, nombre de paramètres et coût observé. Les durées cumulées des cinq époques, comprenant entraînement et validation, sont d'environ 12,3 minutes pour Vanilla, 12,7 minutes pour CIFG et 18,7 minutes pour WMC. Elles proviennent des historiques sauvegardés dans l'environnement Colab utilisé ; elles ne constituent pas un benchmark matériel contrôlé. La réduction du nombre de paramètres de CIFG ne se traduit donc pas, dans ces mesures, par un temps inférieur à Vanilla.

WMC améliore le Macro-F1 par rapport à Vanilla, mais n'atteint pas CIFG et demande davantage de calcul. Ce résultat concerne une longueur maximale de 128 tokens, cinq époques et un seul jeu d'hyperparamètres de référence. Il ne permet pas de généraliser le classement à d'autres tâches ou à des séquences plus longues.

Déséquilibre et validité du protocole

Un classifieur prédisant systématiquement « positif » obtiendrait, d'après la distribution du test, 65,96 % d'accuracy mais seulement environ 0,2650 de Macro-F1. CIFG dépasse donc ce repère simple sur les deux mesures. Ce repère est calculé à partir des effectifs ; il ne correspond pas à un quatrième modèle entraîné. La classe neutre demeure difficile, en raison possible de son faible effectif et du caractère ambigu des notes intermédiaires.

La troncature peut supprimer des éléments de fin d'avis utiles au sentiment. Les cibles issues des notes ne constituent pas une annotation linguistique indépendante. Le dédoublonnage ne garantit ni une séparation par médicament, ni l'absence de textes très proches. Enfin, une seule graine et l'absence d'intervalles de confiance limitent l'interprétation des écarts. Le réglage complémentaire ne concerne que Vanilla ; CIFG et WMC n'ont pas bénéficié d'une recherche d'hyperparamètres équivalente.

Reproductibilité et pistes de prolongement

Chaque expérience sauvegarde sa configuration, l'historique des métriques, le meilleur état et un checkpoint de reprise après chaque époque. Une empreinte des données et du vocabulaire protège contre une reprise sur des données différentes. Les entraînements ont été sauvegardés avec PyTorch 2.11.0+cu130 ; l'évaluation finale a été réalisée après passage à l'environnement CPU 2.11.0+cpu. La comparaison de configuration a été adaptée pour accepter ces variantes de la même version, sans ignorer les autres paramètres. Le CPU permet de poursuivre l'inférence sans réentraîner les modèles terminés.

Les prolongements prioritaires sont de répéter les expériences avec plusieurs graines, de régler les trois architectures avec un budget identique, de comparer plusieurs longueurs de séquence et d'étudier l'effet des poids de classes. Une séparation par médicament ou une détection de quasi-doublons renforcerait aussi l'évaluation de généralisation.

Conclusion

L'étude retient **CIFG**, sélectionné sur la validation et confirmé par le meilleur Macro-F1 observé au test, **0,5923**. Le couplage des portes réduit la taille du modèle tout en améliorant ici l'équilibre des performances entre classes. La reconnaissance des avis neutres reste le principal axe de progression ; les faibles écarts entre variantes doivent être confirmés par des répétitions indépendantes.

Références et sources expérimentales

[1] UCI Machine Learning Repository. Drug Review Dataset (Drugs.com), jeu de données 462. archive.ics.uci.edu/dataset/462.
[2] Greff K. et al. LSTM: A Search Space Odyssey. IEEE TNNLS, 2017. arxiv.org/abs/1503.04069.
[3] Landi F., Baraldi L., Cornia M., Cucchiara R. Working Memory Connections for LSTM. Neural Networks, 2021. arxiv.org/abs/2109.00020.
Sources des chiffres et figures : fichiers CSV, configurations JSON et historiques contenus dans Sauvegarde_RNN_corrigee.zip, export fourni le 20 octobre 2026.